Classificação de expressões faciais utilizando algoritmos de aprendizado de máquina: uma comparação entre regressão linear e classificadores Bayesianos Gaussianos

Heitor Teixeira
Centro de Ciências Tecnológicas
UNIFOR
Fortaleza, Brasil
heitor@unifor.br

***Abstract*—Este estudo tem como objetivo a análise de dados para classificação, utilizando os métodos dos mínimos quadrados ordinário e regularizado, bem como os classificadores Bayesianos Gaussianos. Além do gráfico de dispersão já conhecido previamente em sala de aula, foram utilizados os gráficos de boxplot e o gráfico de Função de Densidade de Probabilidade (PDF) para cada uma das 5 classes que representam diferentes expressões faciais. A análise preliminar dos dados mostrou que o conjunto de dados é composto por 50.000 observações para os dois sensores de eletromiografia. As classes são totalmente balanceadas e foram importadas de 2 arquivos, EMG.csv que contém as 50.000 observações ($X \in RN \times p$), enquanto o arquivo Rotulos.csv contém as 50.000 classes ($Y \in RN \times C$).**

Em síntese, este estudo apresenta uma análise de dados para classificação utilizando diferentes métodos, incluindo uma análise preliminar dos dados e a avaliação do desempenho do modelo por meio de testes de validação com base em sua acurácia.

Keywords*—*Least squares method, Gaussian Bayesian classifiers, Machine learning, Linear regression.

I. Introdução

O presente artigo visa comparar o desempenho de modelos de Regressão Linear (Ordinary Least Squares - OLS e OLS regularizada) e Classificadores Bayesianos Gaussianos na resolução de problemas de classificação. O estudo utiliza a linguagem de programação Python e diversas bibliotecas, como Numpy, Pandas, Matplotlib, Plotly, Seaborn e Sklearn, para implementação e análise dos modelos propostos. Este artigo está organizado da seguinte forma: a Seção 2 descreve a metodologia utilizada na análise, incluindo a preparação e visualização dos dados, a implementação dos modelos de regressão linear e classificadores bayesianos gaussianos e a análise de resultados; a Seção 3 apresenta os resultados obtidos; e a Seção 4 oferece as conclusões e considerações finais.

II. Metodologia

A. *Preparação e Visualização dos Dados*

O conjunto de dados foi importado e armazenado em um dataframe do Pandas. Para facilitar a visualização, rótulos textuais foram criados para cada classe. Gráficos de dispersão e boxplots foram gerados usando a biblioteca Plotly para explorar as características dos dados. Os dados gerados foram com base no ‘x1’. A análise preliminar revelou a presença de ruídos (outliers) mas nenhum dado foi removido nesse estágio.

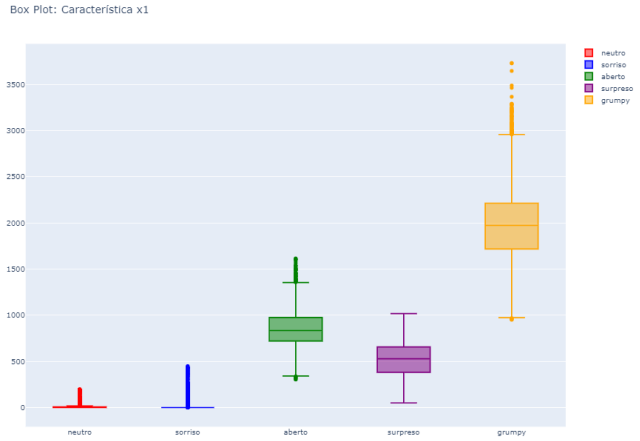

Fig. 1. Boxplot x1 .

B. *Modelos de Regressão Linear*

A regressão linear é um método estatístico que visa modelar a relação entre uma variável dependente e uma ou mais variáveis independentes. A Regressão Linear Ordinária (Ordinary Least Squares - OLS) é uma das técnicas mais comuns para realizar essa modelagem. O objetivo do OLS é encontrar os coeficientes que minimizam a soma dos quadrados das diferenças entre os valores observados e os previstos pelo modelo linear.

Neste estudo, foi implementada uma classe chamada OLS em Python, que recebe os dados de entrada, saída e um valor lambda para regularização. O algoritmo de treinamento e previsão é executado automaticamente ao criar uma instância dessa classe.

A classe OLS implementada permite o treinamento e previsão do modelo de regressão linear ordinária de maneira eficiente e automatizada. Além disso, fornece métodos para avaliar a acurácia e a matriz de confusão do modelo, facilitando a análise dos resultados.

No treinamento do modelo de regressão linear ordinária, adicionamos uma coluna de 1s à matriz de entrada (X) para representar o bias. O bias é um termo constante adicionado à equação linear, permitindo que o modelo ajuste-se melhor aos

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

dados e não passe necessariamente pela origem. A inclusão do bias aumenta a flexibilidade do modelo e, na maioria dos casos, melhora o ajuste aos dados de treinamento.

Entretanto, o treinamento sem bias (sem a coluna de 1s) foi realizado para responder a um questionamento específico: como o modelo de regressão linear ordinária se comporta quando não incluímos o termo de bias? Neste caso, o modelo é forçado a passar pela origem, ou seja, a linha de regressão deve começar no ponto (0,0). Isso pode ser útil em algumas situações, mas geralmente resulta em um ajuste menos preciso aos dados.

Para realizar o treinamento sem bias, a classe OLS recebe um argumento opcional 'sem_uns', que, quando definido como True, remove a coluna de 1s da matriz de entrada e treina o modelo sem o termo de bias. Ao comparar os resultados do modelo treinado com e sem bias, podemos avaliar a importância do termo de bias e entender seu impacto no ajuste do modelo aos dados.

A OLS regularizada adiciona um termo de penalização aos coeficientes, que é controlado por um parâmetro chamado lambda. Essa regularização tem como objetivo evitar o sobre ajuste do modelo aos dados de treinamento, resultando em uma melhor capacidade de generalização para dados não vistos.

Quando lambda é igual a zero, a OLS regularizada se torna equivalente à OLS não regularizada, já que o termo de penalização é nulo. Ao ajustar o valor de lambda, é possível encontrar um equilíbrio entre a complexidade do modelo e sua capacidade de generalizar.

A OLS regularizada foi testada com diferentes valores de lambda, variando entre [0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.9, 1]. No entanto, não foram observadas mudanças significativas na acurácia ao variar o valor de lambda, resultando em uma acurácia constante de 71,53%. Um laço de repetição de 100 iterações foi executado com lambda = 0.2 para verificar a estabilidade do modelo, que apresentou acurácia próxima a 72%, indicando treinamento adequado e confiabilidade. Contudo, a aplicabilidade do modelo de classificação é limitada pela acurácia de 70%, considerada baixa para algumas aplicações.

A seguir, serão apresentados os gráficos dos hiperplanos gerados pela matriz sem bias, com bias e a matriz de confusão. A análise desses gráficos nos ajudará a entender o impacto do termo de bias e da regularização no desempenho do modelo.

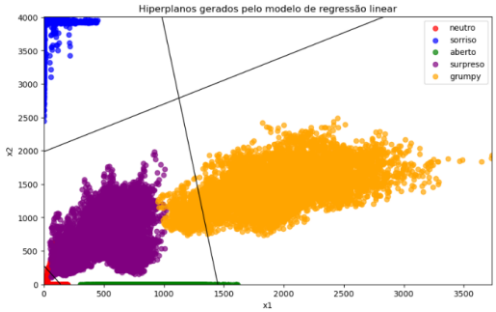

Fig. 2. Gráfico de dispersão com hiperplanos com bias.

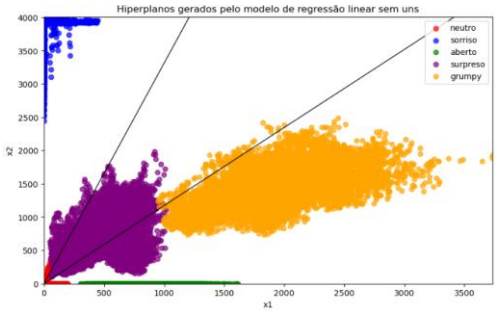

Fig. 3. Gráfico de dispersão com hiperplanos sem bias.

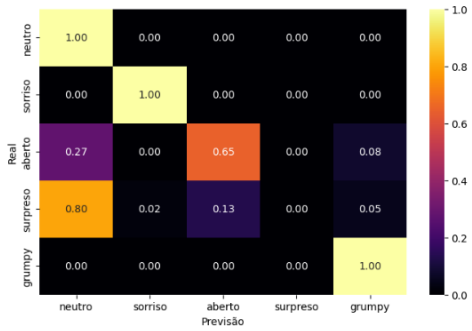

Fig. 4. Matriz de confusão OLS.

C. *Classificadores Bayesianos Gaussianos*

Após a análise dos modelos de regressão linear, os classificadores bayesianos gaussianos foram aplicados. Inicialmente, informações essenciais como médias de x1 e x2, desvios padrão de x1 e x2, matriz de covariância e probabilidade a priori foram definidas e armazenadas. Gráficos de Função Densidade de Probabilidade (FDP) para x1 e x2 foram plotados para analisar as probabilidades de cada classe em relação aos valores de x1 e x2.

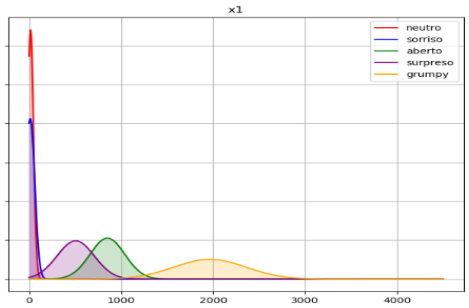

Fig. 5. Gráfico FDP x1 .

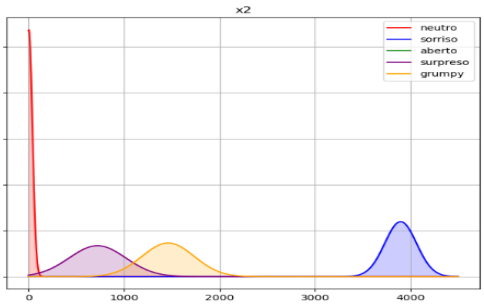

Fig. 6. Gráfico FDP x2 .

Após análise, os dados de treino e teste foram separados novamente para uso nos classificadores bayesianos gaussianos. O primeiro passo consistiu em calcular a matriz de covariância comum a todos os dados e as matrizes de covariância individuais de cada classe. A função discriminante baseada na matriz de covariância comum alcançou uma acurácia de 95%, um resultado significativamente melhor em comparação aos modelos de regressão linear. A análise dos gráficos de FDP sugeria que essa melhoria era esperada, devido à distinção clara de probabilidade e ocorrências ao correlacionar x1 e x2.

Em seguida, o método da matriz de covariância agregada (pooled) foi aplicado. Com matrizes de covariância individuais, a acurácia permaneceu acima de 96% em todos os treinos. Na matriz de confusão deste método, a única classe com desempenho inferior a 97% foi a classe "surpreso", com 85%, sendo que 10% de seus dados foram confundidos com a classe "neutro". A análise dos gráficos também indicava essa possibilidade.

A abordagem de covariância agregada individual consiste em calcular uma matriz de covariância separada para cada classe nos dados. Essa abordagem permite que o modelo de classificação leve em consideração as diferenças na variabilidade entre as classes. Como resultado, o modelo pode ser mais eficaz em distinguir as classes, especialmente em casos onde a estrutura dos dados é complexa e as classes possuem padrões distintos de variabilidade.

Testamos a eficiência do modelo novamente 100 vezes para garantir a confiabilidade do treino e obtivemos a acurácia acima de 96%.

Segue matriz de confusão do modelo abaixo:

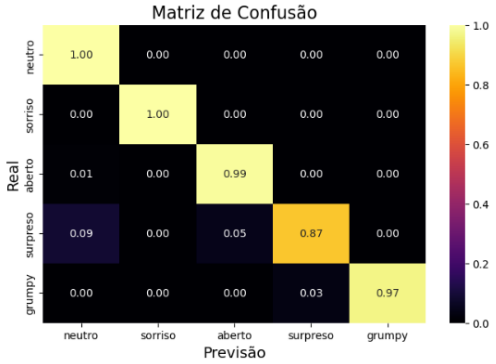

Fig. 7. Matriz de confusão Pooled.

Posteriormente, o método de Friedman foi utilizado. Para aplicá-lo, as matrizes de covariância do método agregado foram ajustadas e um valor épsilon de 1e-6 foi utilizado para possibilitar a inversão da matriz da classe "aberto", cuja matriz de covariância era singular devido à presença de todos os valores de x2 serem iguais a zero.

O método de Friedman é uma técnica de classificação baseada em um modelo discriminante regularizado. Este método consiste na regularização da matriz de covariância utilizando um parâmetro lambda. O objetivo dessa regularização é melhorar a estabilidade numérica do modelo e prevenir overfitting quando há poucas amostras de treinamento ou quando as matrizes de covariância são quase singulares.

Os mesmos valores de lambda utilizados no modelo de regressão linear OLS regularizada foram aplicados no método de Friedman para análise de sensibilidade. Os lambdas utilizados foram [0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.9, 1].

No experimento realizado, foi observado que ao treinar o modelo de Friedman com diferentes valores de lambda, a acurácia aumentava conforme lambda aumentava. A tabela apresentada mostra claramente essa relação entre lambda e a acurácia nos conjuntos de treino e teste. Algumas possíveis razões para essa melhoria na acurácia com o aumento do lambda podem incluir:

- O aumento do lambda pode estar melhorando a estabilidade numérica das matrizes de covariância, tornando o processo de inversão mais confiável e, por sua vez, melhorando o desempenho do modelo.
- A regularização pode estar atuando como um mecanismo de seleção de características, reduzindo a importância das características menos relevantes e aumentando a importância das características mais relevantes para a classificação.

É importante ressaltar que essa relação positiva entre a acurácia e o valor de lambda pode ser específica para este conjunto de dados e não necessariamente se aplicar a outros conjuntos de dados ou situações. No entanto, esses resultados indicam que o modelo de Friedman é capaz de se beneficiar da regularização neste conjunto de dados.

Abaixo segue as acurácias e matriz de confusão do modelo:

	Lambda	Acurácia treino	Acurácia teste
0	0.000000	0.598350	0.600000
1	0.100000	0.742925	0.743100
2	0.200000	0.778025	0.781900
3	0.300000	0.819150	0.821700
4	0.400000	0.862000	0.864300
5	0.500000	0.903400	0.907000
6	0.600000	0.929375	0.931000
7	0.700000	0.944100	0.946200
8	0.900000	0.958000	0.962000
9	1.000000	0.962150	0.964600

Fig. 8. Dataframe de acurácias Friedman.

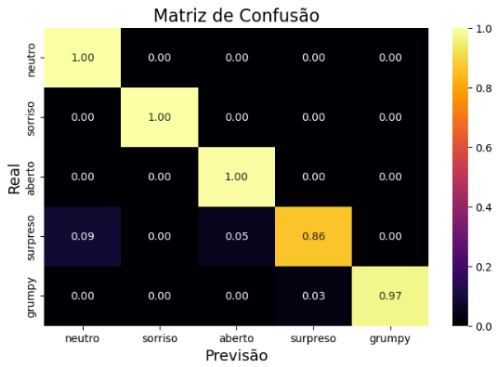

Fig. 9. Matriz de confusão Friedman.

A última implementação realizada no artigo foi o classificador Naive Bayes, que obteve uma acurácia impressionante de 99%. O algoritmo inicia com a divisão dos dados em conjuntos de treino e teste, utilizando a função train_test_split do pacote scikit-learn, neste modelo eu resolvi

separar novamente os dados. Os dados de treino são empregados para calcular as médias e matrizes de covariância das classes, enquanto os dados de teste são usados para avaliar a acurácia do modelo.

Para cada classe, o código calcula a média e a matriz de covariância dos dados de treino. Um valor epsilon é adicionado à matriz de covariância para garantir que ela seja invertível. Em seguida, o modelo é testado e a acurácia é calculada com base nas previsões e nos rótulos verdadeiros dos dados de teste.

Algumas observações importantes sobre o código e o desempenho do classificador Naive Bayes:

- A alta acurácia obtida pelo modelo indica que ele é bastante eficaz na classificação dos dados. Isso sugere que as características selecionadas são informativas e discriminativas, permitindo ao modelo distinguir as classes com sucesso.
- O uso de matrizes de covariância diagonal comum para cada classe simplifica o modelo e reduz o número de parâmetros a serem estimados. Isso pode tornar o modelo mais robusto e menos propenso a overfitting.
- O classificador Naive Bayes assume que as características são condicionalmente independentes dadas as classes. Embora essa suposição possa não ser verdadeira em muitos casos, o desempenho obtido pelo modelo demonstra que ele é capaz de fornecer resultados satisfatórios mesmo com essa simplificação.

Em resumo, a implementação do classificador Naive Bayes neste estudo demonstrou um excelente desempenho, alcançando uma acurácia de 99%. A simplicidade do modelo, combinada com a eficácia das características selecionadas, permitiu uma classificação bem-sucedida das classes nos dados analisados.

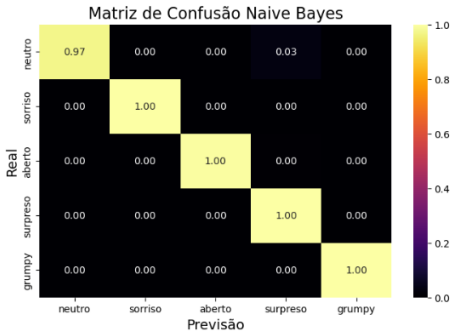

Fig. 10. Matriz de confusão Naïve Bayes.

III. Análises

Neste estudo, foram implementados e comparados três métodos de classificação: Regressão Linear Ordinária (OLS), OLS com Regularização de Ridge e Naive Bayes. As abordagens foram aplicadas a um conjunto de dados de expressões faciais, visando prever a classe de expressão com base em características extraídas. As acurácias alcançadas pelos modelos foram as seguintes: OLS sem bias (40%), OLS com bias (73%), Friedman com regularização (acurácia variando entre 60% e 96%, dependendo do valor de lambda) Agregada 96% e Naive Bayes (99%).

A. OLS

A OLS foi aplicada ao problema de classificação utilizando uma abordagem de treinamento com e sem bias (constante). Foi observado que o modelo sem bias obteve uma acurácia inferior (40%) em comparação com o modelo com bias (73%). Além disso, o estudo investigou o impacto da regularização de Ridge na performance do modelo, observando que a acurácia não se alterava conforme o valor de lambda aumentava.

	Lambda	Acurácia treino	Acurácia teste
0	0	72.345000	71.750000
1	0.100000	72.345000	71.750000
2	0.200000	72.345000	71.750000
3	0.300000	72.345000	71.750000
4	0.400000	72.345000	71.750000
5	0.500000	72.345000	71.750000
6	0.600000	72.345000	71.750000
7	0.700000	72.345000	71.750000
8	0.900000	72.345000	71.750000
9	1	72.345000	71.750000

Fig. 11. Dataframe de acurácias OLS regularizada .

B. Classificadores Bayesianos Gaussianos

Os Classificadores Bayesianos Gaussianos, como o Naive Bayes, apresentaram resultados significativamente melhores do que a OLS, indicando que são uma opção mais eficiente para a classificação de expressões faciais com base nas características extraídas.

Todos esses classificadores apresentaram uma acuracia superior a 95%.

IV. Conclusão

Os métodos de classificação analisados neste estudo apresentaram resultados distintos. A Regressão Linear Ordinária sem bias teve a menor acurácia, enquanto os Classificadores Bayesianos Gaussianos, como o Naive Bayes, obtiveram a maior acurácia, chegando a 99%.

A análise da matriz de confusão para o Naive Bayes revelou um excelente desempenho do classificador na identificação das expressões faciais. Este resultado sugere que os Classificadores Bayesianos Gaussianos são uma abordagem muito eficiente para a classificação de expressões faciais com base nas características extraídas.

Em resumo, este estudo demonstrou a aplicabilidade e a eficácia de diferentes métodos de classificação para a previsão de expressões faciais Coletadas como descrito no documento passado pelo professor.

V. Observações

O algoritmo e os questionamentos a mais que não foram respondidos no artigo estão no link dos comentários.